周语昕

求职意向：AI 评测 / AI 应用（实习）

13022069636 / zyx167167@qq.com
GitHub：github.com/inwardzyx（两个仓库，CI 均绿）
到岗时间：**可立即到岗**，每周 4–5 天，可连续 6 个月

专业技能

评测与判据	105 题盲出独立集（44+61）、exact McNemar 配对检验、噪声地板、变异测试、失败归因分桶
评测基建	报告运行指纹（代码 / 语料 / 依赖 / PDF 后端）、新鲜度检查（引用过期即红）、CI 准入、口径单一来源
AI 应用	RAG（向量 + BM25 + RRF）、LLM 精排与拒答策略、DeepSeek 接入、MCP server
后端与前端	Spring Boot 3 + MySQL 8 + Redis（REST、JWT、配额、审计）· Vue 3 + TypeScript + Vite
交付与运维	Docker Compose 五容器、Nginx 反代与上传限额、Cloudflare Tunnel、GitHub Actions

项目经历

LLM 评测流水线 —— 把「改动有没有变好」变成可复核的结论（独立开发）

2026.10 – 2026.11

一条**单消费者**评测流水线：评测集 → 判据 → 执行 → 门禁 → 报告，**被测对象是下面的制度问答系统**； 刻意不建平台接口 —— 只有一个消费者，多一层抽象只多一层没人调的代码。

我的工作

- **指标与口径**：3 条检索层指标（Recall@5 / 漏答 / 拒答准确），**分母各自算**；口径只写一处， 报告全脚本生成、**数字不手抄**，改一个跑批 JSON 报告就跟着变。
- **数据与版本**：**105 题盲出独立集**（44 应答 + 61 拒答）+ sha256 + pre-push 校验； 改任何一题都会被拦下，避免「用自己调过的题证明自己」。
- **先量噪声，再谈差异**：同配置重跑 4 次得观测极差（Recall@5 ±1 / 漏答 0 / 拒答 ±1）， 小于等于该幅度不作解释；改动一律用 **exact McNemar 配对检验** 判定。
- **门禁与自证**：每条判据配一条**变异用例**（改 k、改比对字段、把指标写反）证明它会红； 跨层直接拒绝比较；κ 在样本 <20 时**拒绝输出。**
- **可追溯**：每份报告带**运行指纹**（git sha + 逐目录语料哈希 + 依赖指纹 + 可用 PDF 后端）； **报告过期合法，「引用过期报告」才报红** —— 这一条把「README 与产物一起过期」也堵住了。

制度问答台 —— 企业制度问答系统（被测对象）

2026.09 – 2026.11

员工用自然语言提问，**答案下方带原文条款出处**；资料里没有就明确拒答、**不编造。** 按「谁在问、能问什么、问了多少次」拆成 Java 业务层与 Python 算法层。

关键实现

- **权限**：角色在业务层一次性投影成 ACL（未登记角色直接 403、不降级），算法层只认 ACL。 实测同一问题：**人事命中薪酬条款并带出处，普通员工被明确拒绝**，请求参数一个字没变。
- **检索与成本**：向量 + BM25 + RRF + LLM 精排；条款号写进索引后条款类命中 **2/15 → 13/15。** 每日配额在**调模型之前**判定，超限 429 且**不产生模型费用。**
- **结果**：**63 条后端 + 4 条前端 + 473 条算法层测试**；五容器一条命令起、公网可访问，一次问答约 **4 秒。**

教育背景

韩山师范学院 | 软件工程（五年制专本衔接） 2025 – 2030