周语昕

求职意向：AI 应用开发 / 全栈开发（实习）

13022069636 / zyx167167@qq.com
GitHub：github.com/inwardzyx
可实习：**1 月 15 日起，每周 4–5 天，可连续 4–6 个月**

专业技能

前端	Vue 3 + TypeScript + Vite；组件化、路由守卫、开发代理与生产同源反代
后端	Java 17 / Spring Boot 3（Web、Validation、Actuator）、MyBatis-Plus、JWT(HS256)、BCrypt、统一错误模型
数据	MySQL 8（建表 / 索引 / 时区）、Redis（原子计数 + 按天 TTL）
AI 工程	RAG（向量 + BM25 + RRF）、LLM 精排与生成、拒答策略、评测集与配对显著性检验、MCP
工程化	Docker Compose 多容器编排、Nginx 反代、GitHub Actions、pytest / JUnit / Vitest

项目经历

制度问答台 —— 三层架构的企业问答系统

个人项目 · 2026.10 – 2026.11

Vue 3 + TypeScript + Vite | Spring Boot 3 + MyBatis-Plus | MySQL / Redis | Docker Compose + Nginx | 对接 Python 算法服务

- **分层设计**：按「谁在问、能问什么、问了多少次」切成三层 —— 前端 → Java 业务层（用户 / 角色 / 配额 / 审计）→ 无状态的算法服务（检索 / 精排 / 生成）。**配额在调用模型之前判定**，超额请求不产生任何 token 费用。
- **权限（核心）**：角色 → ACL **单向投影**（employee → public；hr → hr, public；未登记角色 403 不降级），身份只解析一次，下游只认 ACL 不认角色。实测同一问题：**hr 命中「加班与补贴」并带原文引用，employee 明确拒答**；而 employee 问「年假」可正常回答 —— 差别只来自令牌里的角色。
- **配额与审计**：Redis `INCR` + 按天 `TTL` 实现每人每日额度，超限返回 429 + `Retry-After`；每次问答落库，问题**只存 SHA-256**（可比对频次、还原不出原文），记录 answered / refused / quota_denied / upstream_error 四类决策，`trace_id` 与算法服务对齐。
- **可靠性与安全**：未配内部口令或认证模式为 none 时接口直接 503（fail-closed）；JWT 密钥 < 32 字节启动即失败；健康检查把上游 AI 服务纳入（AI 不可用时整体 DOWN，实测 503）。
- **质量与交付**：**63 条后端测试**（H2 内存库，不依赖本机 MySQL）+ **4 条前端测试** + GitHub Actions 三 job；Compose 编排 web / api / ai / mysql / redis 五容器（全 healthy），Nginx 上传上限与后端 20MB 对齐；公网经 Tunnel 可访问，问答端到端 ≈ 4.0 s。

校园政策问答 RAG 服务

个人项目 · 2026.09 – 2026.10

Python + FastAPI + bge-small-zh（向量）+ jieba/BM25 + RRF + DeepSeek（精排 / 生成）+ Redis + Docker Compose

- **服务与性能**：独立完成的 LLM 问答服务，把 10 份校级制度做成「答案带条款出处、库里没有就当场拒答」的检索问答；FastAPI 多端点（/chat、/chat/stream SSE、/search、/health、/limits、/guard-report），compose 一条命令起；检索端到端 **p50 3.1 ms / p95 7.6 ms**（含向量编码，n=240），单题 2–3 次模型调用约 **946 token**。
- **工具层**：自写 **MCP server / client**（手写 JSON-RPC over stdio，不依赖官方 SDK），把 `search_policy` 从借道 `/chat` 改到 `/search`；配对 A/B 证明**渲染文本逐字节一致（20/20）**、每次省 ≈ **366 token**。
- **入库把关**：286 块原始材料 → **放行 263 / 拦下 23**，每条理由可在 `/guard-report` 逐条查；近似重复阈值 **0.96 是量出来的**（最像的一对合法条款 0.9230、该拦的同义改写 0.9839，两簇之间是空的）。
- **拒答与评测**：精排最高分 < 5 直接返回「我不编」、不调用生成模型；精排挂掉时降级走粗捞并标 `rerank_used=false`。双评测集（调参集 + **105 题盲出独立集**）：Recall@5 **44/44**、漏答率 **4/44 → 1/44**（exact McNemar **p = 0.0156**）；另有三条「看起来更好」的改法被同一门禁在 39 题上同时否决。
- **故障可见性**：`/health` 报四类故障计数（拒绝 / 配额 / 存储错误 / 记账缺口 usage_missing）+ 存储后端；拿不到 usage 记「缺失」**不补 0** —— 这个计数器发现了流式记账的静默丢失。

教育背景

韩山师范学院 | 软件工程（五年制专本衔接，专科段在读） 2025 – 2030（2030 年毕业）