周语昕

求职意向：AI 应用开发 / 全栈开发（实习）

13022069636 / zyx167167@qq.com
GitHub：github.com/inwardzyx （policy-desk：业务 + 前端 · campus-policy-rag：算法层，两个仓库 CI 均绿）
可实习：**1 月 15 日起，每周 4–5 天，可连续 4–6 个月**

专业技能

前端	Vue 3 + TypeScript + Vite；组件化、路由守卫、开发代理与生产同源反代
后端	Java 17 / Spring Boot 3（Web、Validation、Actuator）、MyBatis-Plus、JWT(HS256)、BCrypt、统一错误模型
数据	MySQL 8（建表 / 索引 / 时区）、Redis（原子计数 + 按天 TTL）
AI 工程	RAG（向量 + BM25 + RRF）、LLM 精排与生成、拒答策略、评测集与配对显著性检验、MCP（手写 JSON-RPC）
工程化	Docker Compose 多容器编排、Nginx 反代、GitHub Actions、pytest / JUnit / Vitest

项目经历

制度问答台 —— 面向企业制度的可核验问答系统

个人项目 · 2026.09 – 2026.11

把 10 份制度文档做成「答案带条款出处、库里没有就当场拒答」的问答系统，按 **「谁在问、能问什么、问了多少次」** 拆成 Java 业务层与无状态算法层 —— 算法层不认识「用户」、只认 ACL。

个人工作

- **拆层与配额**：算法层（检索 / 精排 / 生成）与业务层（用户 / 角色 / 配额 / 审计）解耦， 同一套检索可被不同业务复用，也能脱离数据库单测； 配额放在**调用模型之前**判定，超额请求**零 token 消耗**（429 + `Retry-After`）。
- **权限（核心）**：角色 → ACL **单向投影**，身份只解析一次、下游只认 ACL。 实测同一问题：**hr 命中「加班与补贴」并带原文引用，employee 明确拒答**； 而 employee 问「年假」可正常回答 —— 差别只来自令牌里的角色。
- **检索**：向量 + BM25 + RRF 融合 + LLM 精排；把条款号写进索引文本后， 条款类问题 **2/15 → 13/15**（同 32 题配对实验，保留回滚开关）。
- **评测**：双评测集（调参集 + **105 题盲出独立集**，零重合），用 exact McNemar 判定改动是否真有效 （**p = 0.0156**）；另有三条「看起来更好」的改法被同一门禁否决、全部不动。
- **交付**：**63 条后端测试**（H2，不依赖本机 MySQL）+ **4 条前端测试** + CI 三 job； Compose 编排五容器，问答端到端 ≈ **4.0 s**，检索 p50 **3.1 ms**。

项目难点

- **权限要穿过两层，最容易漏在「哪一层」** —— 检索在 Python、身份在 Java，每层各判一次迟早有一层漏。 解法：只保留一处转换（角色 → ACL），**未登记角色直接 403、不降级**（宁可拒绝，不要猜）。
- **入库「该拦的」和「不该拦的」分不开** —— 固定阈值 0.9 误杀合法条款、0.99 又放过同义改写。 解法：先量出两簇的真实分布（最像的合法对 **0.9230**、该拦的改写 **0.9839**，中间是空的）， 据此定 **0.96**；286 块放行 263 / 拦 23，每条理由可逐条查。
- **故障不能被伪装成「库里没有」** —— 精排返回非 JSON 时若给全 0 分，会触发一条平平无奇的拒答， 故障被永久掩盖。解法：抛错并记录原始返回；只有精排 < 5 分才拒答，降级时标 `rerank_used=false`；审计只存问题的 SHA-256（可比对频次、还原不出原文）。

个人收获

一套系统**「能改」比「能跑」难得多**：学会了先写判据再改代码， 也学会了把「不构成证据」的结论如实写下来，而不是挑好看的数字。

技术栈：Vue 3 + TS + Vite ｜ Spring Boot 3 + MyBatis-Plus + MySQL / Redis ｜ Python + FastAPI + bge-small-zh / BM25 / RRF / DeepSeek ｜ Docker Compose + Nginx

教育背景

韩山师范学院 ｜ 软件工程（五年制专本衔接，专科段在读） 2025 – 2030（2030 年毕业）